

RET503 COMPUTER VISION AND DEEP LEARNING · PERTEMUAN 3

Transfer Learning dan Fine-Tuning Model Visi

CLO-2 · SO2-B5 · CDIO Stage #2 Design

Program Studi Teknologi Rekayasa Robotika · Politeknik Negeri Batam



Capaian pembelajaran hari ini

1

Menjelaskan konsep transfer learning dan alasan fitur CNN dapat dipakai ulang

2

Membedakan feature extraction, fine-tuning parsial, dan fine-tuning penuh

3

Mengatur layer freezing dan learning rate saat fine-tuning

4

Memilih model pretrained sesuai batas komputasi robot

5

Menyusun desain awal pipeline persepsi dan mengambil data dari robot

6

Melakukan fine-tuning dengan PyTorch dan membandingkannya dengan pelatihan dari nol

Pre-class 60' · In-class 120' · After-class 60' · Lab 120' + coaching 50'


PERTANYAAN PEMBUKA

Orang yang sudah mahir menyetir mobil biasanya lebih cepat belajar menyetir truk.

Apa yang “dibawa” dari pengalaman lama, dan apa yang harus dipelajari ulang?

Apa hubungannya dengan CNN?

Transfer learning: memakai ulang pengetahuan




Backbone: bagian CNN yang mengekstrak fitur (ResNet, MobileNet, CSPDarknet)

Head: lapisan akhir yang menghasilkan keluaran tugas

Pretrained weights: bobot hasil pelatihan di domain sumber

Pembelajaran tradisional vs transfer learning



Tradisional


tiap tugas belajar dari nol;
pengetahuan tidak disimpan

Transfer learning

tugas baru memakai
pengetahuan tugas lama: lebih
cepat, lebih akurat, data lebih
sedikit

Gambar: towardsdatascience.com, dikutip dari materi Week 13 Transfer Learning

Mengapa fitur CNN bisa dipakai ulang?



UMUM

SPESIFIK DOMAIN SUMBER

Implikasi: lapisan awal bisa dipakai apa adanya; makin dalam lapisannya, makin perlu disesuaikan. Filter tepi yang dipelajari CNN mirip dengan kernel Sobel dari pertemuan 2, bedanya nilai kernel dipelajari dari data.

Keuntungan dan risiko transfer learning

Data lebih sedikit

Ratusan

citra per kelas sering sudah cukup

Pelatihan lebih cepat

Puluhan

epoch, bukan ratusan, untuk konvergen

Generalisasi lebih baik

Stabil

fitur umum membantu mencegah overfitting


Risiko

Negative transfer

domain terlalu berbeda → buka lebih banyak lapisan

Hubungan dengan YOLO: melatih YOLO dari bobot COCO di minggu 6 juga termasuk transfer learning.

Tiga strategi transfer learning



Gambar: towardsdatascience.com, dikutip dari materi Week 13 Transfer Learning

3

Feature extraction

Hanya head dilatih · data sangat sedikit, domain mirip

2

Fine-tuning parsial


Head + blok akhir · data sedang, domain agak berbeda

1

Fine-tuning penuh

Seluruh model · data banyak atau domain sangat berbeda

Feature extraction: backbone beku, head baru



1

Dipotong
classifier lama untuk label sumber

2

Frozen
convolutional layers dari domain sumber

3

Dilatih
classifier baru untuk label target (O1, O2, ...)

Gambar: *researchgate.net* (fig. 4, 342400905), dikutip dari materi Week 13 Transfer Learning

```
for p in m.parameters(): p.requires_grad = False # frozen
m.fc = nn.Linear(512, NUM_CLASSES)               # classifier baru
```

Matriks keputusan strategi

	Domain mirip	Domain berbeda
Data sedikit	Feature extraction Titik awal proyek lab kita	Fine-tuning parsial Mulai dari blok tengah; perbanyak augmentasi
Data banyak	Fine-tuning penuh Learning rate kecil	Fine-tuning penuh Pertimbangkan pelatihan lebih lama

Layer freezing di PyTorch

```
m = models.resnet18(  
    weights=models.ResNet18_Weights.IMAGENET1K_V1)  
  
# bekukan seluruh backbone  
for p in m.parameters():  
    p.requires_grad = False  
  
# head baru, otomatis bisa dilatih  
m.fc = nn.Linear(m.fc.in_features, NUM_CLASSES)  
  
opt = torch.optim.Adam(  
    [p for p in m.parameters() if p.requires_grad],  
    lr=1e-3)
```

1

BatchNorm

Lapisan beku tetap dalam mode eval() agar statistik ImageNet tidak berubah oleh batch kecil.

2

Optimizer

Masukkan hanya parameter yang dilatih.

3

Head baru

Lapisan yang dibuat ulang otomatis requires_grad = True.

Learning rate untuk fine-tuning

Lebih kecil

sekitar 10× lebih kecil dari pelatihan dari nol ($1e-5$ vs $1e-3$)

Discriminative LR

lapisan awal lebih kecil, head lebih besar

Gradual unfreezing


latih head dulu, lalu buka blok demi blok (fastai)

Scheduler

cosine annealing atau one-cycle agar stabil

Contoh discriminative LR

layer1-3



beku / $1e-5$

layer4



$1e-4$

head (fc)



$1e-3$

Samakan preprocessing dengan model sumber

224×224

ukuran input

RGB

urutan kanal (OpenCV
membaca BGR!)

mean

0,485 · 0,456 · 0,406

std

0,229 · 0,224 · 0,225

Pelatihan:
undistort → resize → normalisasi



Deployment di robot:
undistort → resize → normalisasi

Harus identik

Memilih model pretrained untuk robot

Model	Parameter (juta)	GFLOPs	Top-1 ImageNet	Cocok untuk
MobileNetV3-Small	≈ 2,5	≈ 0,06	≈ 67,7%	Raspberry Pi, tanpa GPU
MobileNetV3-Large	≈ 5,5	≈ 0,22	≈ 74,0%	Edge kelas menengah
EfficientNet-B0	≈ 5,3	≈ 0,39	≈ 77,7%	Jetson
ResNet-18	≈ 11,7	≈ 1,8	≈ 69,8%	Praktikum hari ini
ResNet-50	≈ 25,6	≈ 4,1	≈ 76,1%	Workstation GPU

Keluarga YOLO juga punya varian n, s, m dengan trade-off yang sama — dibahas di minggu 6.

Angka perkiraan dari dokumentasi torchvision; dapat berbeda antarversi.

Contoh penerapan: klasifikasi buah dan sayur

An Effect of Transfer Learning and Data Augmentation for Fruit And Vegetable Type Classification

Naurah Nazhifah^{1,a}, Faturahman Yudanto^{1,b}, Muhamad Fahmi^{1,c},
Afiahayati^{1,d*}

¹Master Program in Artificial Intelligence, Department of Computer Science and Electronics, Faculty of Mathematics and Natural Sciences Universitas Gadjah Mada, Indonesia Yogyakarta, Indonesia

^anaurahnazhifah1399@mail.ugm.ac.id, ^bf.yudanto@mail.ugm.ac.id,
^cmuhamadfahmi@mail.ugm.ac.id, ^dafia@ugm.ac.id

Keywords: Data Augmentation, Image Classification, Transfer Learning, ResNet18, VGG16

Abstract. Classification of fruit and vegetable types and conditions have important roles in the food and agricultural industries. One of the important roles is to ensure the product quality. In this research, the classification of fruit and vegetable types and conditions was carried out using a deep learning approach using the VGG16 and ResNet18 models. The used dataset consists of 11,920 image data. The image data are classified into 20 classes which show the type and the condition of fruits and vegetables. Furthermore, model training was carried out using the dataset using transfer learning techniques on the VGG16 and ResNet18 deep learning architecture. Each model training process was done with and without a data augmentation process. The research results show that the ResNet18 model provides higher accuracy than the VGG16 model, namely 96% using augmentation and 95% without augmentation in the classification of fruit and vegetable types. Related to the data augmentation process for each model, the process itself does not affect significantly on model performance since the model performance has already been good.

11.920

citra, 20 kelas jenis dan kondisi


96%

akurasi ResNet18 dengan augmentasi (95% tanpa)

ResNet18 > VGG16

model lebih kecil, akurasi lebih tinggi

Anggaran latensi: 15 FPS = ± 67 ms per frame



Resolusi input: objek kecil/jauh butuh input lebih besar → lebih lambat.

Deployment: pastikan model bisa dikonversi ke ONNX/TensorRT (minggu 10–11).

Daya dan panas: model ringan = robot beroperasi lebih lama.

CDIO STAGE #2

Design: pipeline persepsi untuk proyek Anda

Draf pertama untuk Pj1 · dikumpulkan bertahap hingga minggu 7

Templat dokumen desain (maks. 2 halaman)

Misi proyek

peran persepsi dalam 2–3 kalimat

Kelas objek

daftar + contoh foto

Kamera &udukan

resolusi, tinggi, sudut, jarak kerja

Unit komputasi

perangkat, mode daya, memori

Target kinerja

mAP, FPS onboard, kalau ada latensi ROS2

Kandidat model

minimal satu + alasan

Strategi TL

strategi awal + alasan

Rencana data

jumlah per kelas, variasi

Risiko

minimal tiga + mitigasi

Mengambil data di lingkungan operasi

- ✓ Jarak: dekat, sedang, jauh
- ✓ Posisi di citra: tengah dan tepi
- ✓ Orientasi: tegak, miring, terbalik
- ✓ Cahaya: terang, redup, jendela, bayangan
- ✓ Latar: meja, lantai, objek pengganggu
- ✓ Sulit: occlusion, tumpuk, motion blur

```
dataset_raw/  
├── metadata.csv  
├── baut/  
│   └── baut_20261001_lab_terang_001.png  
└── mur/  
    └── mur_20261001_lab_redup_001.png
```

metadata.csv: nama_file, kelas, tanggal, kondisi_cahaya — membantu analisis kegagalan di minggu 8 dan 12.

Target minggu ini: ≥ 50 citra per kelas

Praktikum P2: alur 120 menit



```
python capture.py baut terang # langkah 1, per kelas & kondisi
python split.py               # langkah 2
python train.py               # langkah 3: feature | partial | scratch
python latency.py             # langkah 4: ResNet-18 vs MobileNetV3-Small
```

Eksperimen: tiga mode pada ResNet-18

Mode	Bobot awal	Yang dilatih	Learning rate
feature	ImageNet	fc saja	1e-3
partial	ImageNet	layer4 + fc	1e-4 / 1e-3
scratch	acak	semua	1e-3

Yang dicatat: akurasi val terbaik, waktu pelatihan, epoch saat akurasi $\geq$ 90%.

Augmentasi train: RandomResizedCrop, HorizontalFlip, ColorJitter · 10 epoch · CosineAnnealingLR

```
if mode == "partial":
    return Adam([
        {"params":
            m.layer4.parameters(),
            "lr": 1e-4},
        {"params":
            m.fc.parameters(),
            "lr": 1e-3}])
```

Waspada data leakage

Masalah

Frame beruntun dari posisi hampir sama masuk ke train dan val sekaligus.

Akibatnya akurasi validasi terlihat terlalu bagus, tetapi model gagal di lapangan.

Solusi

Pisahkan data berdasarkan sesi atau kondisi pengambilan.

Keluaran P2 dan tugas after-class

Dikumpulkan ke LMS dalam bentuk link github

- Dokumen desain awal (per kelompok)
- dataset_raw + metadata.csv, ≥ 50 citra/kelas
- Tabel hasil 3 mode + grafik akurasi per epoch
- Latensi model yang dipilih
- Analisis singkat (README)

MINGGU DEPAN · PERTEMUAN 4

Persiapan dan anotasi dataset dalam format YOLO dan COCO

Referensi: [2] Goodfellow dkk. 2016 · [4] Howard & Gugger 2020 · Yosinski dkk. 2014 · Zeiler & Fergus 2014 · Materi Week 13 Transfer Learning, Polibatam